

LABORATÓRIO 3: Regressão Linear - Desemprego nos EUA entre 1950 a 2019

Fernando Bispo, Jeff Caponero

Sumário

Introdução	2
Metodologia	2
Objetivos	2
Análise dos dados	2
Análise Preliminar	2
Regressão Linear	5
Conclusão	6

Introdução

Composto por 54 observações, o conjunto de dados em estudo traz informações pertinentes o Índice de desemprego e a Índice de suicídio nos EUA no período entre 1950 e 2019.

O presente relatório tem como objetivo a introdução das técnicas de Regressão Linear Simples e a prática da elaboração de relatórios analíticos fundamentados na Análise Exploratória de Dados, preenchendo assim os pré-requisitos solicitados para o conjunto de dados proposto.

Metodologia

Serão realizadas análises sobre o levantamento das Índices de desemprego e o índice de suicídios nos EUA para o período de 1950 a 2019. Ressalta-se que o índice de suicídios foi calculado para cada 1000 habitantes.

As variáveis contidas no arquivo “desemprego.csv” são:

- Ano (**ano**);
- Índice de Desemprego por 1000 habitantes (**desemp**);
- Índice de Suicídio por 1000 habitantes (**suic**).

Objetivos

O objetivo dessa análise visa responder aos seguintes tópicos:

- Identificar, por meio da análise dos dados, se a Índice de suicídios é função linear do desemprego.
- Obter as estimativas das variâncias de β_0 e β_1 .
- Testar a significância do modelo e reportar a conclusão obtida a um nível de significância de 5%
- Obter os intervalos de confiança para os parâmetros do modelo com o nível de 95% de confiança e interpretar os resultados.

Análise dos dados

Análise Preliminar

A Tabela 1 traz as principais medidas resumo das variáveis em análise, viabilizando assim uma análise preliminar desses dados.

Tabela 1: Medidas resumo dos Índices de desemprego e suicídio nos EUA de 1950 a 2019

	DESEMP	SUIC
Mín	3,50	10,20
Q1	4,87	11,10
Med	5,60	12,05
Média	6,00	11,98
Q3	7,00	12,50
Máx	9,70	14,20
Desv.padrão	1,61	0,95
CV	0,27	0,08
Assimetria	0,63	0,22
Curtose	-0,50	-0,56

Legenda:

¹ DESEMP = Índice de Desemprego

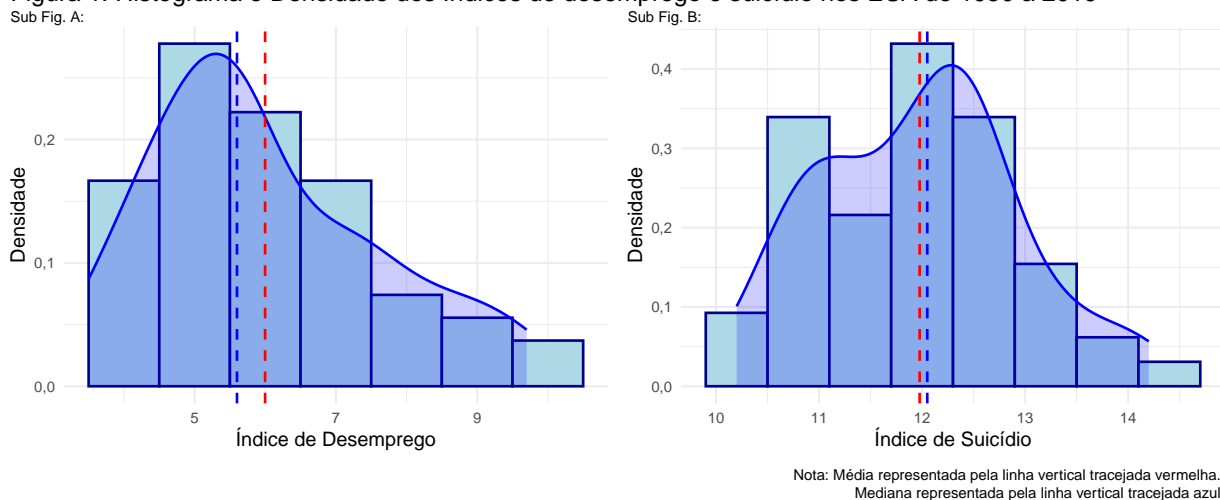
² SUIC = Índice de Suicídio

Fonte: Laboratório 3, Disciplina Análise de Regressão 2023.1.

Para uma primeira análise é possível concluir que a variável Índice de Desemprego apresenta uma maior variabilidade dos dados, em comparação com o Índice de Suicídio, fato esse constatado pelo Coeficiente de Variação, caracterizando assim uma maior homogeneidade dos dados obtidos referente ao o Índice de Suicídio.

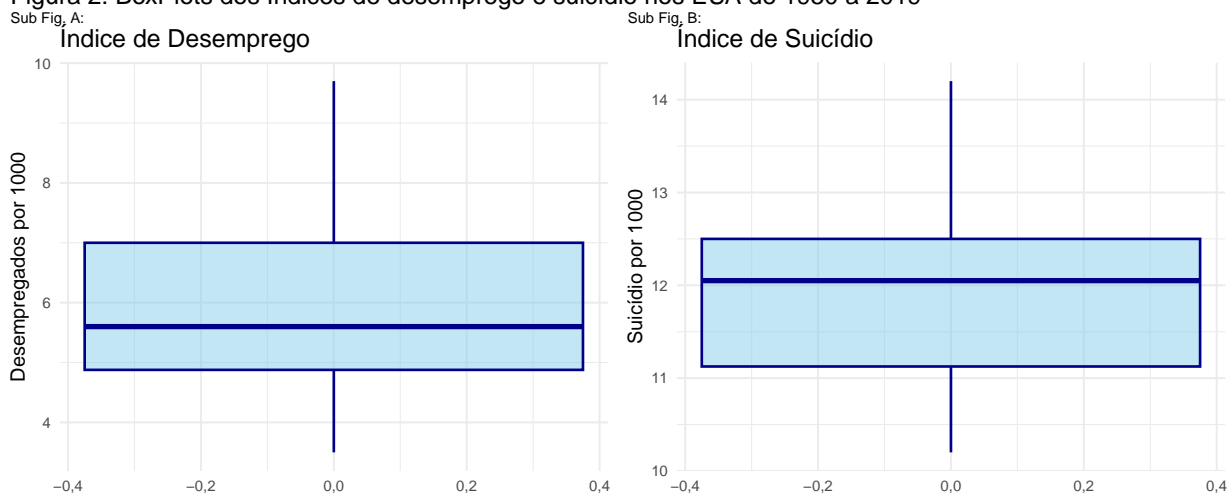
Com relação ao Coeficiente de Assimetria, ambas as variáveis possuem valores de assimetria positiva, indicando que a maioria dos valores são menores que a média. Já com base no Coeficiente de Curtose é possível identificar um comportamento Platocúrtico dos dados, ou seja, um comportamento mais achatado da distribuição dos dados. A análise gráfica facilitará a identificação das informações trazidas pela tabela em análise.

Figura 1: Histograma e Densidade dos Índices de desemprego e suicídio nos EUA de 1950 a 2019



Conforme identificado na Tabela 1, a Figura 1 traz a representação gráfica das conclusões realizadas para os dados, no que diz respeito a assimetria e curtose.


Figura 2: BoxPlots dos Índices de desemprego e suicídio nos EUA de 1950 a 2019




A análise dos *BoxPlots*, Figura 2, traz pouco mais informação, uma vez que agora é possível verificar com mais facilidade a inexistência de valores discrepantes (*outliers*) que poderiam influir negativamente na regressão linear.

Figura 3: Evolução dos Índices de Desemprego e Suicídio nos EUA entre 1950 e 2019

Sub Fig. A:




Sub Fig. B:



Através da Figura 3 é possível avaliar a evolução dos índices em análise ao longo do tempo, em que é possível identificar uma queda no Índice de Desemprego nos anos finais em que os dados foram coletados, contudo o Índice de Suicídio está apresentando um sinal de queda após um longo período de alta.

A Figura 4 foi desenvolvida a fim de identificar a relação entre as variáveis em análise.

Figura 4: Relação entre Índice de Desemprego e a Índice de Suicídio entre 1950 e 2019, nos EUA



Após análise da Figura 4 não se identificou uma evidente correlação entre as variáveis em análise. Para avaliar a força dessa possível correlação foi realizado o cálculo do Coeficiente de Correlação de Pearson ($\hat{\rho}$), medida que avalia o grau da correlação linear entre variáveis, em que se obteve o valor de 0.2752, caracterizando uma baixa relação entre as variáveis.

Para avaliar a significância da correlação segue a Tabela 2 com os resultados do Teste de Hipóteses com nível de significância de 5% que tem como hipóteses:

$$H_0 : \hat{\rho} = 0$$

$$H_1 : \hat{\rho} \neq 0.$$

Tabela 2: Teste de Hipótese para Correlação

	Resultados
t	2,06387
p-valor	0,04404
LI	0,00799
LS	0,50566

Legenda:

¹ t = Estatística t-Student

² p-valor = Probabilidade de que a estatística do teste tenha um valor extremo em relação ao valor observado quando a hipótese

³ LI: Limite Inferior do Intervalo de Confiança

⁴ LS: Limite Superior do Intervalo de Confiança


Nota: Teste realizado com 5% de significância

Conforme expresso na Tabela 2, levando em consideração o **p-valor** a Hipótese Nula foi rejeitada, e com 95% de confiança se pode afirmar que é significativa a relação linear entre as variáveis em estudo.

Regressão Linear

Tendo em vista a existência de correlação linear entre as variáveis, foi construída a Figura 5, em que se acrescentou a Reta de Regressão Estimada aos dados em análise, sendo esta:

$$\hat{Y} = 10,9994 + 0,1628X_i$$



A Figura 5 traz a implementação da reta de regressão ajustada, além da equação da reta e dos Coeficientes de Correlação, Coeficiente de Determinação e Coeficiente de Determinação Ajustado. Tendo em vista o valor do Coeficiente de Determinação é possível constatar que este não é um bom modelo, pois o modelo explica aproximadamente apenas 7,6% das informações, ou seja, apenas 7,6% das informações referentes ao Índice de

Suicídio são explicadas pelo Índice de Desemprego, sendo assim não faz sentido continuar a análise baseado neste modelo.

Conclusão

Embora havendo uma correlação linear entre as variáveis, esta não foi suficientemente forte para viabilizar a construção de um modelo de Regressão Linear Simples, mesmo sendo feita a estimação da reta, esta não foi suficiente para explicar significativamente os Índices de Suicídio.